

Glossary – Ngày 27

Giải thích các thuật ngữ tiếng Anh xuất hiện trong lab. Đọc khi gặp từ lạ – không cần học thuộc hết.

Kinh tế học AI

Usage unit

Hành động nhỏ nhất mà AI làm trong 1 lần chạy. Ví dụ: 1 ticket được phân loại, 1 câu trả lời được tạo, 1 đoạn tóm tắt. Mỗi usage unit có chi phí riêng (token + model). *Trong lab này, usage unit chính là “1 lượt chat” – 1 lần model AI nhận message và trả lời.*

Job to be Done

Việc người dùng thực sự cần xong, không phải 1 hành động AI riêng lẻ. Thường 1 job = 3–5 usage units xếp chuỗi. *Ví dụ: tourist hỏi “do I need a visa?” – job = “tìm hiểu xong visa requirement”. Để xong job có thể cần: phân loại intent + tra cứu RAG + web search + tạo câu trả lời = 4 usage units.*

Variable cost vs Fixed cost

Chi phí biến đổi (variable) thay đổi theo lượng dùng – phần mềm AI là dạng này, mỗi lần model chạy = tốn tiền. Chi phí cố định (fixed) không đổi theo lượng dùng – phần mềm truyền thống chủ yếu là dạng này. **Sự khác biệt này là nền tảng của AI Product Economics.**

Cost of Revenue

Chi phí để phục vụ 1 đồng doanh thu. AI products thường có Cost of Revenue cao hơn SaaS truyền thống vì phải trả tiền cho mỗi inference (token + API).

AI margin gap

Sự chênh lệch margin: SaaS truyền thống 80–90% gross margin, AI products thường chỉ 50–60%. Lý do: cost biến đổi cao + 1 power user có thể phá unit economics.

ROI (Return on Investment)

Tỷ lệ giá trị / chi phí. Ngưỡng quyết định trong stress test: **>3:1 = GO**, **1–3:1 = CONDITIONAL**, **<1:1 = NO-GO**.

Reality discount

Hệ số nhân giảm khi tính giá trị thật của AI feature. Công thức tham khảo: adoption ~70% × quality ~80% ≈ 56% → làm tròn xuống **50%** cho an toàn (cho người mới triển khai chưa có data thực tế).

Stress test

Kiểm tra ROI ở 3 kịch bản: Base (kỳ vọng), Cost × 2 (provider tăng giá hoặc overuse), Value ½ (adoption thấp hoặc AI kém chất lượng), và combined (cả hai cùng lúc). Mục đích: phơi bày giả định nào yếu nhất.

Pricing & monetization

Cost-Capability-Speed Triangle (*Reforge*)

Tam giác đánh đổi 3 trục – model rẻ thường không mạnh, model mạnh thường chậm, model nhanh thường đắt. **Chọn 2 trong 3. Dùng để quyết định model nào cho task nào.**

Monetization Triad (*Reforge*)

Bộ ba ràng buộc của pricing: **Customer Value × Growth Loop × Cost of Revenue**. Cả 3 phải align – đổi 1 góc → cascade cả 3. Pricing nằm ở giao điểm.

Value Metric Spectrum (*Reforge*)

Phổ 5 cách định giá: **Seat → Flat → Usage → Outcome → Hybrid**. Đi từ “dễ làm, weak alignment” sang “khó làm, strong alignment”. *Hybrid đang chiếm 41% thị trường (tăng từ 27% trong 12 tháng).*

Attribution × Autonomy Matrix (*Madhavan Ramanujam*)

Ma trận 2 trục để chọn pricing model: – **Autonomy**: AI tự làm (high) hay AI hỗ trợ (low)? – **Attribution**: Kết quả quy cho AI (high) hay team effort (low)?

Mỗi quadrant gợi ý 1 pricing model: Seat / Subscription / Usage / Outcome.

CAMP Framework (Kyle Poyar)

4 tiêu chí để outcome-based pricing khả thi: – **Consistency** – outcome có nhất quán không? – **Attribution** – có rõ AI gây ra outcome không? – **Measurability** – đo được real-time không? – **Predictability** – duy trì được unit economics đa dạng khách không?

Chỉ ~5% AI products đáp ứng được cả 4 → chọn được outcome-based pricing.

Exploration Penalty

Hậu quả tâm lý khi user bị tính phí metered trong giai đoạn khám phá sản phẩm – user self-censor, không bao giờ tới aha moment. *Đó là lý do free tier thường cần có, dù tốn cost.*

Pricing models

Tiered pricing

Các tier giá cố định, ceiling rõ. **Ví dụ:** GitHub Copilot \$10 → \$19 → \$39. Predictability cao, nhưng power user hit ceiling.

Progressive pricing

Bắt đầu free hoặc rẻ, scale dần lên paid khi user value tăng. **Ví dụ:** Grammarly Free → \$12 → Enterprise. Low barrier, nhưng revenue delay.

Hybrid pricing

Base subscription + credit/usage component. **Ví dụ:** Clay \$149/mo + 2,000 credits, Miro \$8/seat + AI credits. Captures all usage levels, nhưng billing complex.

Outcome-based pricing

Tính phí theo kết quả AI giao được, không tính theo input/usage. **Ví dụ:** Intercom Fin \$0.99/resolution. Chỉ work nếu đủ CAMP – Intercom Fin build đến \$100M+ AI agent revenue.

Seat-based pricing

Tính phí theo user, không theo usage. **Ví dụ:** Notion AI \$10/user/month. Predictable nhưng đang giảm thị phần (21% → 15% trong 12 tháng – Kyle Poyar 2025).

Thuật ngữ kỹ thuật trong lab

RAG (Retrieval-Augmented Generation)

AI tra cứu knowledge base (kho tài liệu) trước khi trả lời. Trong lab: top-5 chunks được lấy ra từ KB $\approx$ 1,250 tokens cố định, đẩy vào input cho mỗi lượt chat.

Chunk

1 đoạn nhỏ tài liệu sau khi cắt knowledge base ra. Trong lab: 1 chunk $\approx$ 250 tokens $\approx$ 150–200 từ.

Token

Đơn vị nhỏ AI dùng để tính. $\sim$ 3–4 ký tự tiếng Anh = 1 token. Giá API tính theo \$/M tokens (1 triệu tokens).

Inference

1 lần AI tính toán + phản hồi. Mỗi inference = 1 lần tốn tiền API.

Embedding

Chuyển text thành vector số để AI search. Trong lab: dùng OpenAI `text-embedding-3-small` (\$0.02/M tokens). Indexing cost cho 30K tokens KB = \$0.0006 – gần như miễn phí.

Web search API

Dịch vụ tìm kiếm real-time để bổ sung context cho AI. Trong lab: Tavily $\sim$ \$0.005–\$0.008/query. Bật khi cần info mới (visa policy, thời tiết, sự kiện).

History management

Cách quản lý lịch sử conversation đẩy vào context mỗi turn. 3 options trong lab: – **Full**: giữ toàn bộ – tokens tăng mỗi turn. – **Last N**: chỉ giữ N lượt gần nhất – cap tokens. – **Summarize**: tóm tắt lịch sử cũ thành $\sim$ 150 tokens – tiết kiệm nhưng cần 1 LLM call phụ.

Intent classification

Phân loại ý định của user message để route đúng. 2 options trong lab: – **Keyword/regex**: rule-based, \$0/message, miss được nuance. – **LLM classifier**: model cheap ($\sim$ 170 tokens), hiểu context tốt hơn nhưng tốn \$.

Handoff

Chuyển conversation từ AI sang con người (sales hoặc manager). Trong lab: Booking → sales, Khiếu nại → manager. Cost AI = \$0 cho phần handoff (nhưng có thể tốn classifier nếu dùng LLM intent).

Verdict (quyết định cuối)

GO

ROI base > 3:1 + ROI worst case (combined stress) > 1:1. Triển khai pilot.

CONDITIONAL

ROI 1–3:1 hoặc < 1:1 ở 1 stress scenario. Triển khai có điều kiện – phải fix cái yếu nhất trước.

NO-GO

ROI < 1:1 ở base case. Thiết kế lại hoặc dừng.

Glossary D27 · cập nhật ngày dạy. Nếu thấy thuật ngữ khác chưa có trong list này → hỏi giảng viên hoặc TA.